

Flappy Bird AI Project

V2025114_박준형

프로젝트 개요 & 목표

- 최종 목표

강화학습을 통해 Flappy Bird 게임 환경에서 장애물을 피하며 생존 시간을 최대화하는 자율 주행 에이전트 개발

- 핵심 알고리즘

연속적인 의사결정 문제에 적합하고 학습 안정성이 뛰어난 PPO (Proximal Policy Optimization) 알고리즘 채택

- 학습 환경

OpenAI Gym 인터페이스와 호환되는 flappy-bird-gymnasium 라이브러리를 사용하여 표준화된 학습 환경 구축

- 기대 효과

불안정한 초기 탐색을 극복하고, 파이프 위치에 따라 최적의 점프 타이밍을 학습하여 인간 수준 이상의 점수 획득



Policy Gradient

On-policy 방식의 학습으로
샘플 효율성과 안정성 확보

프로젝트 범위



강화학습 & PPO 알고리즘

- Reinforcement Learning

에이전트가 환경과 상호작용하며 상태(State)에 따른 행동(Action)을 선택하고, 누적 보상(Cumulative Reward)를 최대화하는 정책(Policy)을 학습하는 과정

- Proximal Policy Optimization (PPO)

TRPO의 복잡성을 개선한 알고리즘. Clipped Surrogate Objective를 통해 정책 업데이트 폭을 제한하여 학습 붕괴를 방지하고 안정성을 확보함


Objective Function

$$L(\theta) = E[\min(r(\theta)\hat{A}, \text{clip}(r(\theta), 1-\epsilon, 1+\epsilon)\hat{A})]$$

- Actor-Critic & GAE


Actor-Critic: 정책(Actor)과 가치함수(Critic)를 동시에 학습
GAE: Generalized Advantage Estimation으로 Bias-Variance Trade-off를 조절하여 효율적 학습 유도

Workflow



Data Flow: 환경 상호작용(Rollout) → Advantage 계산(GAE) → 정책 업데이트(PPO Clip) 반복 수행

환경 설명 : Flappy Bird



- **Visual Observation**

에이전트는 게임 화면(Pixel) 또는 추출된 피쳐(좌표 등)를 관측하여 현재 상태를 판단함

- **Space Definitions**

OBSERVATION SPACE

Box(12,) / RGB Image

ACTION SPACE

Discrete(2)

FEATURE DETAILS

[bird_y, bird_vel, pipe_x, pipe_gap_y, ...]

- **Game Rules**

목표: 파이프 사이를 통과하며 최대한 오래 생존

행동: 0 (No Flap) 또는 1 (Flap - 점프)

종료 조건: 파이프 충돌, 지면(Ground) 접촉, 천장 이탈

- **Reward Structure**

+1.0 파이프 통과 성공 시 (주요 목표)

+0.1 매 프레임 생존 보상 (오래 버티기 유도)

-1.0 충돌 또는 추락 시 (에피소드 종료)

네트워크 구조 : Actor-Critic

Shared Encoder (Backbone)

상태(State)로부터 고차원 특징을 추출하는 공통 신경망.
픽셀 입력 시 CNN, 벡터 입력 시 MLP 레이어를 사용하여
Actor와 Critic이 공유하는 상태 표현(Latent Feature)을 생성

Actor Head (Policy Network)

추출된 특징을 받아 각 행동의 확률 분포를 출력.

Flappy Bird에서는 'Flap' 또는 'No Flap'에 대한 Logits를 생성하고 Softmax 또는 Bernoulli 분포로 변환

Policy Output

$$\pi(a|s) = \text{Softmax}(\text{ActorLayer}(\text{features}))$$


Critic Head (Value Network)

동일한 특징을 바탕으로 현재 상태의 가치(State Value)를 스칼라 값으로 추정. 이 값은 학습 시 Advantage 계산의 기준점(Baseline)으로 활용됨

Value Output

$$V(s) = \text{Linear}(\text{CriticLayer}(\text{features}))$$

Architecture



Architecture: Shared Backbone에서 Actor(π)와 Critic(V)으로 분기되는 Two-Head 구조




하이퍼파라미터 설정

PARAMETER	VALUE	DESCRIPTION
Learning Rate	3e-4	Optimizer (Adam) 학습률
Gamma	0.99	미래 보상에 대한 할인율 (Discount Factor)
GAE Lambda	0.95	Advantage 추정 시 Bias-Variance 조절 계수
PPO Clip	0.2	정책 업데이트 비율 제한 (ϵ)
PPO Epochs	10	수집된 배치 데이터 학습 반복 횟수
Batch Size	64	업데이트 시 미니배치 크기
N Steps	2048	한 번의 업데이트를 위해 수집하는 타임스텝 수
Entropy Coef	0.01	탐색(Exploration) 유지를 위한 엔트로피 가중치

- Configuration Strategy

Flappy Bird와 같은 간단한 이산 행동 공간(Discrete Action Space)에서는 기본적인 PPO 하이퍼파라미터(Baselines defaults)가 잘 작동함. 초기 탐색을 위해 Entropy Coef를 소량 부여하여 지역 최적해(Local Minima)를 방지함.

학습 과정



TOTAL STEPS
5,001,122
Completed

TOTAL EPISODES
15,304
Avg ~305 steps/ep

PPO UPDATES
2,441
Epochs: 10

MAX REWARD
1,371
New Record

학습 결과

BEST REWARD

1,371.8

Converged Value

BEST SCORE

293

Pipes Passed

AVG SCORE

10.3


Last 100 Episodes

POLICY ENTROPY

0.12

Highly Deterministic

정책 행동 관찰 (Policy Observations)



안정적인 고도 유지 (Stable Hovering)

에이전트는 파이프 통과 직전 수직 속도를 최소화하여 충돌 위험을 줄이는 패턴을 학습했습니다. 불필요한 움직임을 최소화하여 생존 확률을 높입니다.



타이밍 최적화 (Just-in-Time Flap)

하단 파이프에 근접했을 때만 최소한의 Flap을 수행하여, 상단 파이프와의 거리를 확보하고 다음 장애물에 대비할 공간을 만듭니다.

위기 회복 능력 (Emergency Recovery)

예상 경로를 벗어났을 때 연속적인 Flap을 통해 급격히 고도를 수정하는 비상 회복 행동이 관찰되었습니다. 이는 PPO의 탐색 과정에서 습득된 것으로 보입니다.

시연 및 실행 방법



학습된 PPO 에이전트의 플레이 시연 (좌: 실시간 녹화, 우: 목표 성능(100점) 달성 검증)

How to Run

```
$ python train_flappy_bird.py play
```

저장된 모델 가중치(pth)를 로드하여 GUI 환경에서 실행

Key Behaviors Observed

안정적인 고도 유지 (Altitude Control) 파이프 진입 전 적절한 높이를 미리 확보하여 급격한 조작 최소화

파이프 간격 대응 (Gap Navigation) 높은 파이프와 낮은 파이프가 번갈아나올 때 빠른 낙하 및 상승 타이밍 학습

장기 생존 능력 (Long-term Survival) 초반 500k 스텝 이후부터 충돌 빈도가 급격히 감소하며 연속 300개 이상 통과

결론 및 느낀점

프로젝트 성과

PPO 알고리즘을 성공적으로 구현하여 최고 점수 300+의 파이프를 통과하는 안정적인 자율 주행 정책을 확보하였습니다.

주요 인사이트

Clipped Objective가 급격한 정책 변화를 방지하고, GAE를 통해 가치 추정의 편향을 줄여 학습 효율을 크게 향상시켰습니다.

한계점

픽셀 기반 관측 처리에 높은 연산량이 요구되며, 단일 환경에 과적합되어 변형된 환경(속도 변화 등)에 대한 일반화 성능이 부족했습니다.

향후 개선 방향

Frame Stacking을 적용해 시간적 흐름을 반영하고, 다양한 파이프 패턴을 가진 환경에서의 Curriculum Learning을 시도할 계획입니다.



Mission Accomplished

강화학습 에이전트가
인간 수준이상의 플레이를 달성함

습득 역량

